

# **Взвешенный метод наименьших квадратов**

Дмитрий Алексеевич Павлов  
инж.-иссл. Лаборатории Чебышёва СПбГУ  
[d.a.pavlov@spbu.ru](mailto:d.a.pavlov@spbu.ru)

СПбГУ, МКН  
2021

# Линейная регрессия

## Модель

Простая (парная) регрессия  $y = \beta_0 + \beta_1 x + \varepsilon$

Множественная регрессия  $y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + \varepsilon$

$y$  — зависимая переменная (наблюдаемая)

$x_i$  — влияющие переменные (наблюдаемые)

$\beta_j$  — параметры модели (ненаблюдаемые)

$\varepsilon$  — случайные ошибки (шум)

## Наблюдения


$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_k x_{ik} + \varepsilon_i$$

# Линейная регрессия (продолжение)

Дано

$y = (y_1, y_2, \dots, y_n)^T$  – наблюдения

$$X = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1k} \\ 1 & x_{21} & \cdots & x_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{nk} \end{pmatrix}$$



Найти  $\hat{\beta} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k)$  :

$$\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \hat{\beta}_0 \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix} + \hat{\beta}_1 \begin{pmatrix} x_{11} \\ x_{21} \\ \vdots \\ x_{n1} \end{pmatrix} + \cdots + \hat{\beta}_k \begin{pmatrix} x_{1k} \\ x_{2k} \\ \vdots \\ x_{nk} \end{pmatrix} + \begin{pmatrix} r_1 \\ r_2 \\ \vdots \\ r_n \end{pmatrix}$$

# Метод наименьших квадратов

$$\sum_{i=1}^n r_i^2 = (\mathbf{y} - X\hat{\boldsymbol{\beta}})^T (\mathbf{y} - X\hat{\boldsymbol{\beta}}) \rightarrow \min$$


$$\frac{\partial}{\partial \hat{\boldsymbol{\beta}}} \sum_{i=1}^n r_i^2 = \frac{\partial}{\partial \hat{\boldsymbol{\beta}}} \hat{\boldsymbol{\beta}}^T X^T X \hat{\boldsymbol{\beta}} - 2 \frac{\partial}{\partial \hat{\boldsymbol{\beta}}} \hat{\boldsymbol{\beta}}^T X^T \mathbf{y} = 2(X^T X \hat{\boldsymbol{\beta}} - X^T \mathbf{y})$$

$$\frac{\partial}{\partial \hat{\boldsymbol{\beta}}} \sum_{i=1}^n r_i^2 = 0 \Rightarrow \hat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T \mathbf{y} \quad \text{— линейная (по } \mathbf{y})$$

$$E[\varepsilon_i | X] = 0 \Rightarrow E[\hat{\boldsymbol{\beta}}] = \boldsymbol{\beta} \quad \text{— несмещённая}$$

$$\lim_{n \rightarrow \infty} \mathbb{P}[|\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}| < \delta] = 0, \quad \forall \delta \quad \text{— состоятельная}$$

оценка



# Теорема Гаусса-Маркова

Если модель данных *правильно специфицирована* и

$$\text{rank}(X) = k$$

$$\text{Var}[\varepsilon_i] = \sigma^2 < \infty$$

$$\text{E}[\varepsilon_i | X] = 0$$

$$\text{Cov}[\varepsilon_i, \varepsilon_j] = 0, \quad \forall i \neq j$$

то

$$\sum r_i^2 = \min$$

$$\text{Var}[\hat{\beta}] = \sigma^2 (X^T X)^{-1}$$

$\hat{\beta}$  является лучшей из линейных несмещённых оценок  $\beta$

(BLUE – Best Linear Unbiased Estimator)

$$\tilde{\beta} = ((X^T X)^{-1} + D)\mathbf{y} \Rightarrow \text{Var}[\tilde{\beta}] = \text{Var}[\hat{\beta}] + \sigma^2 D D^T$$

# Другие оценки

- Взвешенный метод наименьших квадратов (учитывает различные  $\text{Var}[\epsilon_i]$ , см. далее)

Остальное см. в учебниках:

- Обобщённый метод наименьших квадратов (учитывает корреляции между  $\epsilon_i$ )
- Метод регуляризации Тихонова (учитывает априорное распределение  $\beta$ )
- Метод максимального правдоподобия (эквивалентен МНК при условиях теоремы Гаусса-Маркова и нормальном распределении  $\epsilon_i$ )
- Метод наименьших полных квадратов (учитывает ошибки в зависимых переменных)
- Метод наименьших модулей (устойчив к выбросам в данных)

# Полиномиальная регрессия

$$y = \beta_0 + \beta_1 x + \beta_2 x^2 + \dots + \beta_k x^k + \varepsilon$$

- Модель осталась линейной!
- Корреляции между  $x^j$  не нарушают условий теоремы Гаусса-Маркова.

```
set key left top


system "seq -70 50 | awk -e '\n
{ print $1,\n
  1e-3 * $1**3 + 0.03 * $1**2 - 0.6 * $1 - 8 \n
  + 30 * (rand() - 0.5) }' > ./data.txt"

f(x) = a * x**3 + b * x**2 + c * x + d

fit f(x) "data.txt" using 1:2 via a, b, c, d

plot 'data.txt' using 1:2 with points pt 6 t "Data",\
      f(x) t "Fit" lc rgb "red" lw 2

pause -1
```



Final set of parameters		Asymptotic Standard Error	
=====		=====	
a	= 0.00100756	+/- 2.422e-05	(2.404%)
b	= 0.0301535	+/- 0.001039	(3.446%)
c	= -0.591481	+/- 0.05355	(9.054%)
d	= -7.91562	+/- 1.289	(16.28%)

- Обобщается на произвольное количество переменных.
- Вместо мономов могут быть ортогональные многочлены: Чебышёва, Лежандра, ...

# Взвешивание

$\text{Var}[\varepsilon_i] = \sigma_i^2$       Если дисперсии ошибок различаются, МНК уже не является лучшей оценкой (хотя продолжает быть несмещённой).

$$\frac{y_i}{\sigma_i} = \beta_0 \frac{1}{\sigma_i} + \beta_1 \frac{x_{i1}}{\sigma_i} + \cdots + \beta_k \frac{x_{ik}}{\sigma_i} + \frac{\varepsilon_i}{\sigma_i}$$

$$\text{Var} \left[ \frac{\varepsilon_i}{\sigma_i} \right] = 1 = \text{const}$$

$$\sum_{i=1}^n \frac{r_i^2}{\sigma_i^2} = (\sqrt{W} \mathbf{y} - \sqrt{W} X \hat{\beta})^T (\sqrt{W} \mathbf{y} - \sqrt{W} X \hat{\beta}) \rightarrow \min \quad \sqrt{W} = \begin{bmatrix} \frac{1}{\sigma_1} & & 0 \\ & \ddots & \\ 0 & & \frac{1}{\sigma_n} \end{bmatrix}$$

$$\mathbf{y}' = \sqrt{W} \mathbf{y}, \quad X' = \sqrt{W} X, \quad \mathbf{r}' = \sqrt{W} \mathbf{r}$$

В такой постановке вновь применима теорема Гаусса-Маркова.

$\hat{\beta} = (X^T W X)^{-1} X^T W y$  — лучшая из линейных несмещённых оценок

$$\text{Var}[\hat{\beta}] = (X^T W X)^{-1}$$



# Взвешивание: пример


```
set key left top

system "seq -70 4 50 | awk -e '
{ if (NR % 5 == 0) sigma = 150; else sigma = 15;
  print $1, 1e-3 * $1**3 + 0.03 * $1**2 - 0.6 * $1 - 8 \
  + 2 * sigma * (rand() - 0.5), sigma}' > ./data.txt"

f(x) = a * x**3 + b * x**2 + c * x + d
f1(x) = a1 * x**3 + b1 * x**2 + c1 * x + d1

fit f(x) 'data.txt' using 1:2 via a, b, c, d
fit f1(x) 'data.txt' using 1:2:3 yerrors via a1, b1, c1, d1

plot 'data.txt' using 1:2:3 with yerrorbars pt 6 t "Data", \
      f(x) t "Non-weighted fit" lc rgb "red" lw 2, \
      f1(x) t "Weighted fit" lc rgb "#00AA00" lw 2
pause -1
```



## Невзвешенный МНК

Final set of parameters		Asymptotic Standard Error	
=====			
a	= 0.00112155	+/- 0.0002194	(19.57%)
b	= 0.0334969	+/- 0.009513	(28.4%)
c	= -0.990355	+/- 0.5097	(51.46%)
d	= -20.2313	+/- 12.47	(61.62%)

## Взвешенный МНК

Final set of parameters		Asymptotic Standard Error	
=====			
a1	= 0.000986942	+/- 4.749e-05	(4.812%)
b1	= 0.0278733	+/- 0.002147	(7.702%)
c1	= -0.623062	+/- 0.1102	(17.69%)
d1	= -8.09056	+/- 2.745	(33.93%)

# Оценка дисперсии и ошибка единицы веса

Пусть дисперсия в МНК неизвестна:  $\text{Var}[\varepsilon_i] = \sigma^2 = ?$

$$\hat{\sigma}^2 = \frac{\sum r_i^2}{n - k} \quad \text{— несмещённая оценка дисперсии}$$

Ошибка единицы веса во взвешенном МНК:

$$\mu = \frac{\sum \frac{r_i^2}{\sigma_i^2}}{n - k} \quad (\text{reduced chi-square, regression standard error, variance of unit weight})$$

$\mu \gg 1$  — плохое соответствие между моделью и данными

$\mu \ll 1$  — «перетренированная» модель или слишком пессимистические  
априорные ошибки ( $\sigma_i$ )

$\mu$  около 1 — полный порядок

# Разложение Холецкого

Как вычислить  $(X^T X)^{-1}$  или  $(X^T W X)^{-1}$ ?

*Кто сказал «методом Гаусса»? Никогда не применяйте метод Гаусса.*

$A = X^T W X$  — симметричная положительно определённая матрица.

$$A = LL^T, \quad L = \begin{bmatrix} l_{11} & 0 & \dots & 0 \\ l_{21} & l_{22} & \dots & 0 \\ \vdots & & \ddots & \vdots \\ l_{(k+1)1} & \dots & l_{(k+1)k} & l_{(k+1)(k+1)} \end{bmatrix}$$

$$C \equiv A^{-1} \quad AC = E \Leftrightarrow LB = E, \quad L^T C = B$$

Так как матрица  $L$  — нижняя треугольная, то обе системы решаются последовательным исключением неизвестных.

Осталось найти  $L$ .

# Разложение Холецкого (продолжение)

$$\begin{aligned}l_{11} &= \sqrt{a_{11}} \\l_{j1} &= a_{j1}/l_{11}, \quad j = 2..(k+1) \\l_{ii} &= \sqrt{a_{ii} - \sum_{p=1}^{i-1} l_{ip}^2}, \quad i = 2..(k+1) \\l_{ji} &= \left( a_{ji} - \sum_{p=1}^{i-1} l_{ip} l_{jp} \right) / l_{ii}, \quad i = 2..k, \quad j = (i+1)..(k+1)\end{aligned}$$

Так как  $A$  положительно определенная, то элементы под корнем не могут быть отрицательными.

Выделять память под  $L$  необязательно: можно замещать элементы  $A$ .

Выделять память под  $X$  тем более необязательно:  $A$  нужно строить, последовательно обрабатывая строки  $x_{i1} \dots x_{ik}$ .

# Ссылки

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC392707/pdf/pnas00019-0030.pdf>

[http://web.hku.hk/~pingyu/6005/LN/LN3\\_Least%20Squares%20Estimation-Finite-Sample%20Properties.pdf](http://web.hku.hk/~pingyu/6005/LN/LN3_Least%20Squares%20Estimation-Finite-Sample%20Properties.pdf)

[http://web.hku.hk/~pingyu/6005/LN/LN5\\_Least%20Squares%20Estimation-%20Large-Sample%20Properties.pdf](http://web.hku.hk/~pingyu/6005/LN/LN5_Least%20Squares%20Estimation-%20Large-Sample%20Properties.pdf)

[https://en.wikipedia.org/wiki/Ordinary\\_least\\_squares](https://en.wikipedia.org/wiki/Ordinary_least_squares)

<https://stats.stackexchange.com/a/149111>

[https://en.wikipedia.org/wiki/Proofs\\_involving\\_ordinary\\_least\\_squares](https://en.wikipedia.org/wiki/Proofs_involving_ordinary_least_squares)

[https://en.wikipedia.org/wiki/Weighted\\_least\\_squares](https://en.wikipedia.org/wiki/Weighted_least_squares)

[https://en.wikipedia.org/wiki/Cholesky\\_decomposition](https://en.wikipedia.org/wiki/Cholesky_decomposition)